Datathon 2026: Phân tích dữ liệu và dự báo doanh thu cho doanh nghiệp thời trang thương mại điện tử Việt Nam

Tên đội: ISCS_2022
Trường Đại học Công nghệ Thông tin
Đại học Quốc gia Thành phố Hồ Chí Minh
[thangnv842645@gmail.com]

Thành viên 1: Nguyễn Văn Thắng
MSSV: 22521338
Khoa: Hệ thống thông tin

Thành viên 2: Lâm Tuấn Thịnh
MSSV: 22521409
Khoa: Hệ thống thông tin

Thành viên 3: Nguyễn Ngọc Yến Nhi
MSSV: 22521410
Khoa: Hệ thống thông tin

Thành viên 4: Lê Quý Nhân
MSSV: 22521411
Khoa: Khoa học máy tính

Abstract

Báo cáo trình bày lời giải của nhóm ISCS_2022 cho Datathon 2026 trên hai nội dung: phân tích dữ liệu kinh doanh và dự báo doanh thu ngày cho doanh nghiệp thời trang thương mại điện tử. Ở Phần 2, nhóm xây dựng câu chuyện dữ liệu theo bốn lớp Descriptive, Diagnostic, Predictive và Prescriptive để chỉ ra vấn đề về tăng trưởng, promotion, logistics và hành vi mua lại. Ở Phần 3, nhóm xây dựng pipeline dự báo Revenue và COGS theo nguyên tắc không rò rỉ dữ liệu, sử dụng đặc trưng lịch, lag/rolling, historical profile, LightGBM, SHAP và blending với seasonal baseline. Mục tiêu của pipeline là cân bằng giữa hiệu quả dự báo, khả năng giải thích và tính tái lập.

1 Phần 2 — Trực quan hóa và phân tích dữ liệu

Phần phân tích được triển khai theo hướng **data storytelling**, tập trung trả lời: doanh nghiệp đang tăng trưởng ở đâu, vì sao doanh thu suy giảm và cần ưu tiên hành động nào. Các phân tích được tổ chức theo bốn cấp độ: Descriptive, Diagnostic, Predictive và Prescriptive.

1.1 Descriptive: Bức tranh kinh doanh giai đoạn 2012–2022

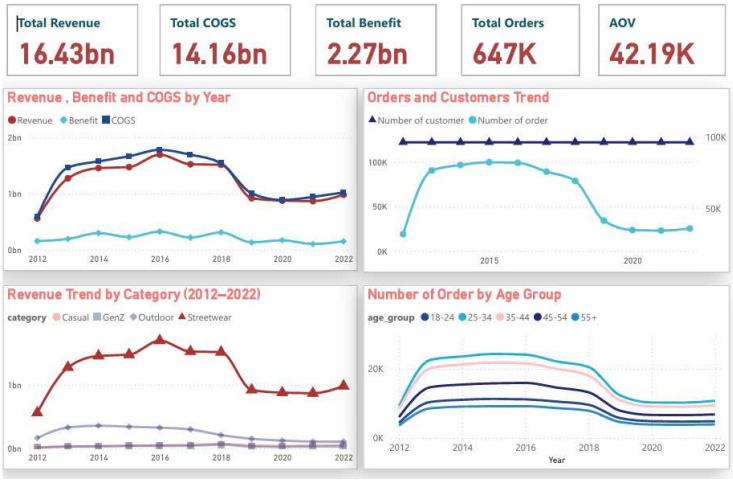

Hình 1: Tổng quan KPI và xu hướng theo năm, danh mục và nhóm tuổi giai đoạn 2012–2022.

Hình 1 cho thấy doanh nghiệp đạt khoảng **16.43 tỷ** doanh thu và **2.27 tỷ** lợi nhuận. Tuy nhiên, COGS chiếm gần **86%** doanh thu, phản ánh biên lợi nhuận còn thấp. Doanh thu tăng mạnh ở giai đoạn đầu, đạt đỉnh quanh **2016–2017**, sau đó giảm liên tục từ năm 2018.

Về sản phẩm, doanh thu phụ thuộc đáng kể vào nhóm **streetwear**. Về khách hàng, số lượng khách và AOV không giảm mạnh, trong khi số đơn hàng suy giảm sau năm 2018. Vì vậy, vấn đề chính không chỉ là mất khách hay giảm giá trị đơn, mà nhiều khả năng đến từ **tần suất mua hàng thấp hơn**.

1.2 Diagnostic: Nguyên nhân suy giảm hiệu quả kinh doanh

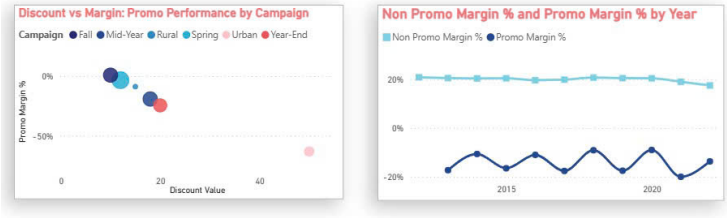

Hình 2: Phân tích hiệu quả promotion: margin theo năm, mức discount và campaign.

Hình 2 cho thấy nhóm giao dịch có promotion có biên lợi nhuận thấp hơn rõ rệt so với nhóm không promotion. Promo margin thường rơi vào vùng âm, khoảng -10% **đến** -20%, trong khi non-promo margin duy trì quanh **18%–21%**. Khi discount tăng lên khoảng **15%–20%**, margin giảm sâu hơn. Điều này cho thấy promotion có thể làm tăng doanh thu danh nghĩa nhưng chưa chắc tạo ra lợi nhuận thực.

Bên cạnh đó, doanh thu trong giai đoạn có promotion không tăng tương ứng với mức chiết khấu. Do đó, promotion không phải nguyên nhân duy nhất giải thích revenue decline sau năm 2018. Vấn đề lớn hơn nằm ở tần suất mua hàng, chất lượng campaign và khả năng giữ chân khách hàng.

Hình 3: Hiệu suất vận chuyển: thời gian giao hàng và customer rating theo khu vực.

Hình 3 cho thấy thời gian giao hàng trung bình khoảng **4–5 ngày**; customer rating dao động khoảng **3.8–4.0**. Khác biệt giữa các vùng không lớn, nên logistics chưa phải nút thắt chính. Điều này giúp nhóm tập trung vào các yếu tố có khả năng ảnh hưởng mạnh hơn như promotion, retention, danh mục sản phẩm và tồn kho.

1.3 Predictive: Tín hiệu dự báo rủi ro

Từ các phân tích trên, nhóm nhận diện ba tín hiệu có giá trị dự báo. Thứ nhất, doanh thu có tính mùa vụ theo năm và theo quý, đặc biệt thường cao hơn trong **Quý 2**. Thứ hai, tần suất mua hàng giảm là tín hiệu sớm của rủi ro doanh thu giảm. Thứ ba, tồn kho, stockout, fill rate, web traffic và mức độ promotion có thể đóng vai trò biến dẫn dắt nếu được chuyển hóa thành đặc trưng lịch sử an toàn.

Do tập test không công bố dữ liệu tương lai từ các bảng transaction và operational, nhóm không dùng trực tiếp orders, traffic, inventory hoặc promotion trong tương lai. Các tín hiệu này được biến đổi thành *historical profile* theo tháng, ngày trong tuần hoặc nhóm mùa vụ để hỗ trợ mô hình ở Phần 3 mà không gây rò rỉ dữ liệu.

1.4 Prescriptive: Khuyến nghị hành động

Từ kết quả phân tích, nhóm đề xuất bốn hướng hành động. **Thứ nhất**, tối ưu promotion bằng cách giảm campaign discount cao, chuyển sang ưu đãi có điều kiện cho nhóm khách có khả năng mua lại hoặc nhóm sản phẩm cần đẩy tồn kho. **Thứ hai**, tái phân bổ ngân sách marketing sang các kênh tạo traffic chất lượng như Organic Search và Social Media, thay vì phụ thuộc quá nhiều vào giảm giá trực tiếp. **Thứ ba**, đặt campaign gần giai đoạn nhu cầu tự nhiên tăng, đặc biệt quanh Quý 2. **Thứ tư**, giảm return bằng cách cải thiện size chart, gợi ý size theo lịch sử mua hàng và mô tả sản phẩm rõ hơn, nhất là khi *wrong size* là một lý do hoàn trả nổi bật.

2 Mô hình dự báo doanh thu

2.1 Chiến lược tổng quan

Bài toán Phần 3 là dự báo Revenue theo ngày cho giai đoạn 01/01/2023–01/07/2024. Pipeline được xây dựng theo nguyên tắc không rò rỉ dữ liệu: đặc trưng của ngày dự báo chỉ được tạo từ thông tin lịch hoặc dữ liệu đã biết trong quá khứ. Các bảng orders, payments, shipments, returns, reviews, inventory và web traffic chỉ được dùng dưới dạng historical profile.

Nhóm dự báo Revenue trước, sau đó dự báo tỷ lệ giá vốn trên doanh thu:

$$COGS_ratio = \frac{COGS}{Revenue}, \qquad COGS_{pred} = Revenue_{pred} \times COGS_ratio_{pred}.$$

Cách tiếp cận này giúp COGS ổn định hơn vì giá vốn thường biến động cùng chiều với doanh thu.

2.2 Feature engineering và huấn luyện

Pipeline tạo hơn 500 đặc trưng, gồm ba nhóm chính. Nhóm thứ nhất là đặc trưng lịch như ngày trong tuần, tháng, quý, tuần trong năm, cuối tuần và mã hóa chu kỳ sin/cos. Nhóm thứ hai là đặc trưng lịch sử của chuỗi mục tiêu, gồm lag 1, 2, 7, 14, 28, 364, 365 ngày và rolling statistics theo nhiều cửa sổ. Nhóm thứ ba là historical profile từ các bảng phụ, ví dụ số đơn, số lượng sản phẩm, discount, tỷ lệ promotion, stockout days, fill rate, sell-through rate, sessions và page views.

Tại inference, nhóm dùng recursive forecasting: dự báo của ngày hiện tại được đưa trở lại lịch sử để tạo lag và rolling cho các ngày tiếp theo. Cách này giữ logic tạo đặc trưng thống nhất giữa validation và test.

Do dữ liệu có thứ tự thời gian, nhóm không dùng random K-Fold mà áp dụng Time-Series Expanding Window. Các fold lần lượt train trên 2012–2017, 2012–2018, 2012–2019, 2012–2020, 2012–2021 và validation trên từng năm tiếp theo từ 2018 đến 2022. Mô hình chính là LightGBM Regressor, phù hợp với dữ liệu bảng nhiều đặc trưng và quan hệ phi tuyến (2). Các tham số như learning rate, num leaves, max depth, feature fraction, bagging fraction và regularization được kiểm soát, kết hợp early stopping trên validation theo thời gian.

2.3 Giải thích mô hình và ensemble

Để giải thích kết quả, nhóm sử dụng SHAP nhằm xác định các biến đóng góp mạnh nhất vào dự báo (3). SHAP Summary được chuyển xuống Appendix để tiết kiệm không gian phần chính. Kết quả cho thấy các đặc trưng quan trọng gồm Revenue_lag_1, các lag theo năm như Revenue_lag_365, COGS_lag_365, COGS_lag_364, biến ngày trong tháng và một số tín hiệu vận hành. Điều này phù hợp với logic kinh doanh: doanh thu chịu ảnh hưởng bởi quán tính ngắn hạn, mùa vụ năm và khả năng đáp ứng hàng hóa.

Để giảm sai số tích lũy của recursive forecasting, nhóm blending LightGBM với seasonal baseline:

$$Final_Pred = 0.85 \times LightGBM + 0.15 \times Seasonal_Naive_{lag364}.$$

Cách kết hợp dự báo bằng trọng số giúp tận dụng đồng thời khả năng học phi tuyến của LightGBM và vai trò neo mùa vụ của seasonal naive, phù hợp với hướng forecast combination trong chuỗi thời gian (1). Thành phần seasonal baseline đặc biệt hữu ích trong giai đoạn test dài, khi mô hình recursive có thể bị lệch dần khỏi cấu trúc mùa vụ.

2.4 Đánh giá và khả năng tái lập

Mô hình được đánh giá bằng MAE, RMSE và R^2. Ngoài điểm tổng thể, nhóm kiểm tra sai số theo tháng để đánh giá khả năng giữ đúng biên độ mùa vụ. Toàn bộ pipeline dùng cùng một hàm tạo đặc trưng cho train, validation và inference; random seed được cố định khi cần thiết. Nhóm không dùng dữ liệu ngoài, không dùng Revenue/COGS thật của tập test và không merge dữ liệu tương lai từ các bảng transaction hoặc operational.

3 Kết luận

Báo cáo kết hợp phân tích kinh doanh và mô hình dự báo trong một pipeline thống nhất. Phần 2 giúp nhận diện vấn đề về biên lợi nhuận, promotion, tần suất mua hàng và mùa vụ. Phần 3 chuyển các insight này thành hệ thống dự báo có kiểm soát leakage, tận dụng đặc trưng lịch, lịch sử doanh thu, historical profile và blending theo mùa vụ. Hướng tiếp cận này không chỉ tối ưu điểm số mô hình mà còn hỗ trợ các quyết định thực tế về tồn kho, promotion, marketing và vận hành.

Tài liệu

[1] J. M. Bates and C. W. J. Granger. The combination of forecasts. *Operational Research Quarterly*, 20(4):451–468, 1969.

[2] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

[3] S. M. Lundberg and S.-I. Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

A Phụ lục: SHAP summary cho mô hình Revenue

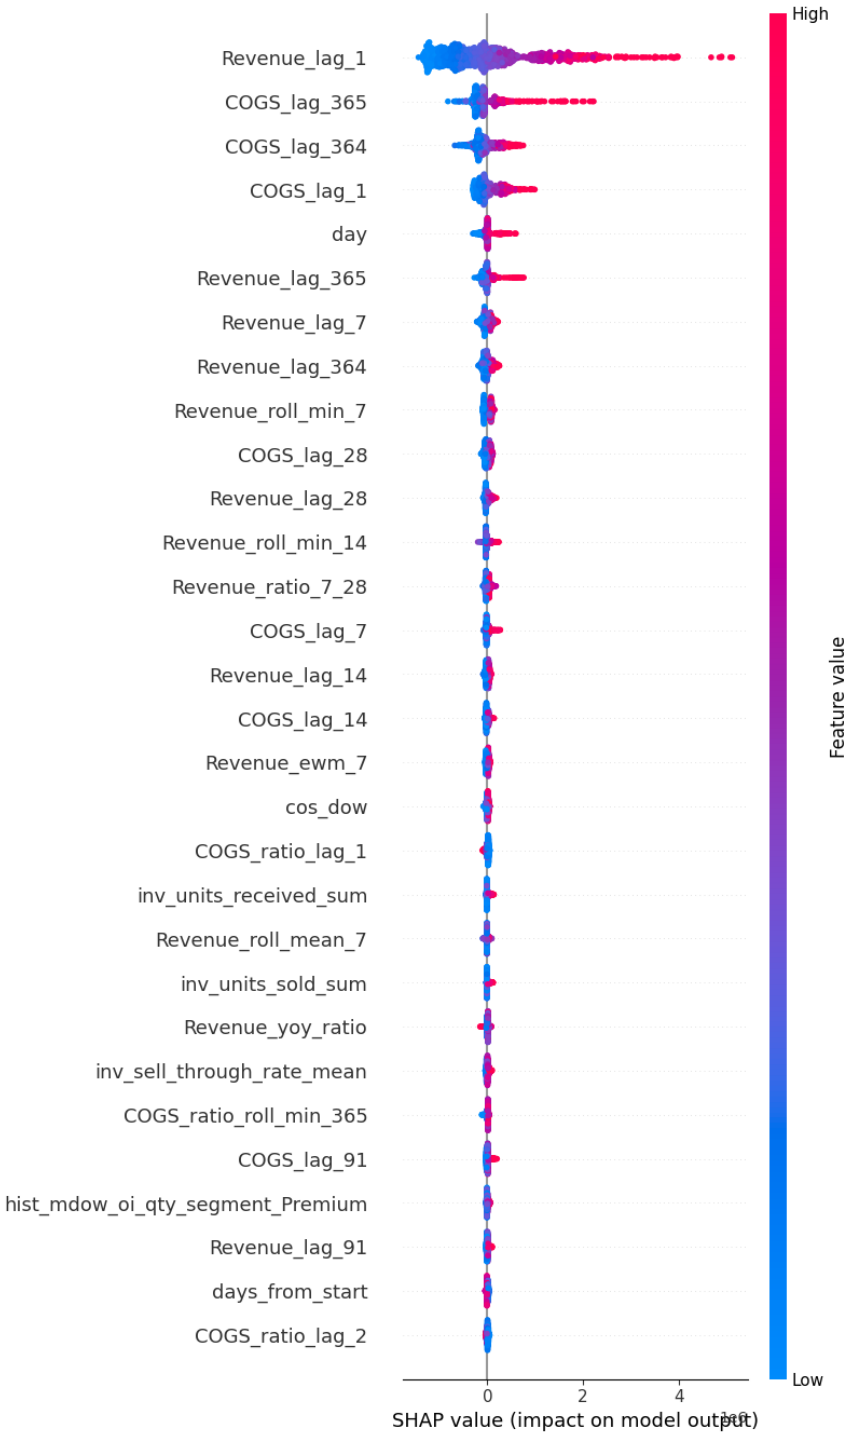

Hình 4: SHAP Summary mô tả mức độ tác động của đặc trưng tới output của mô hình Revenue.